AUGUSTO MELO RIBEIRO

AI Engineer | LLMs, RAG e Sistemas Multiagente | Machine Learning em Produção

Campinas/SP | rguto11@gmail.com
Portfólio: rguto11.github.io | linkedin.com/in/rguto11 | github.com/rguto11

RESUMO PROFISSIONAL

Estagiário de IA em fintech e estudante de Ciência de Dados e Inteligência Artificial (PUC-Campinas, formatura em julho de 2027). Construo sistemas de IA do protótipo ao Docker, com testes: assistentes multiagente com RAG, chat analítico com LLM (tool calling e Text-to-SQL seguro) e modelo de churn com LightGBM em pipeline agendado. Meu projeto público de agentes tem 342 testes automatizados. Base sólida em Matemática e desenvolvimento assistido por IA.

COMPETÊNCIAS TÉCNICAS

LLMs e IA Generativa: OpenAI API (GPT-4o), Gemini API, Ollama, LangChain, engenharia de prompts, tool calling, saídas estruturadas, RAG, embeddings, Text-to-SQL, agentes de IA e sistemas multiagente, guardrails, avaliação de modelos.

Machine Learning: Scikit-learn, LightGBM, XGBoost, CatBoost, K-Means, PCA, Optuna, feature engineering, classificação, clusterização, predição de churn.

Engenharia e MLOps: Python, FastAPI, APIs REST, Pydantic, SQLAlchemy, Pytest, Git, Docker, CI/CD (GitHub Actions), pipelines de ML agendados, Domain-Driven Design, React e TypeScript (noções práticas).

Dados e BI: SQL, PostgreSQL, MySQL, Redis, Pandas, NumPy, SciPy, ETL, AWS RDS, Streamlit, Plotly, Power BI, Excel avançado, Power Query, VBA.

EXPERIÊNCIA PROFISSIONAL

ValePay | Estagiário de Inteligência Artificial | Campinas/SP | Maio 2026 – Atual

- Desenvolvi uma plataforma de analytics para fintech com 14 domínios de negócio isolados (Domain-Driven Design), integrando LLMs, machine learning e automação, com desenvolvimento assistido por IA.
- Construí um chat analítico com LLM (GPT-4o e Ollama) para consultar dados em linguagem natural: orquestrador com memória de contexto, tool calling por domínio, introspecção automática de schema e validação de SQL com sqlglot (Text-to-SQL seguro), com troca entre modelo em nuvem e local e mascaramento de dados pessoais (PII).
- Treinei um modelo LightGBM multi-class de churn comportamental com 60 features de dados transacionais (ratios de 30/60/90 dias, tendências, frequência, ticket médio, velocidade de inatividade) e o operacionalizei num pipeline agendado a cada 6 horas: extração do MySQL, inferência, clustering K-Means e gravação atômica no PostgreSQL, com distributed locking via Redis e scripts Lua.
- Modelei o Lifetime Value normalizado por volume transacional e analisei 30 meses de dados financeiros, simulando cenários de repricing para recuperação de margem.
- Automatizei a comunicação com clientes com um motor de Customer Lifecycle Management de 11 réguas via WhatsApp e prioridade mutex entre funnels.
- Expus os modelos e as análises em APIs FastAPI (JWT com refresh token, RBAC, 2FA, rate limiting e audit logging) e em um dashboard Streamlit/Plotly com 28 views.
- Containerizei a stack (API, dashboard, worker, PostgreSQL e Redis) com CI/CD no GitHub Actions, testes com Pytest e Makefile com mais de 20 comandos automatizados.

Projetos internos e confidenciais: posso detalhar a arquitetura em entrevista.

Ceva Saúde Animal | Analista de BI Jr. | Paulínia/SP | Março 2026 – Maio 2026

- Desenvolvi pipelines em Python para dados comerciais e de mercado da unidade de Aves, com dashboards de vendas, market share e preços e análises usadas em negociações com clientes.

Ceva Saúde Animal | Estagiário de Business Intelligence | Paulínia/SP | Março 2024 – Fevereiro 2026

- Automatizei processos que antes eram manuais com pipelines ETL em Python para dados comerciais e de mercado.

- Construí dashboards em Power BI e Excel, com automação via Power Query e VBA, para o acompanhamento mensal de vendas e KPIs.
- Elaborei estudos analíticos para a diretoria e o time comercial, como cobertura do mercado de vacinas e estimativas de preços da concorrência.

E. E. Professor Alberto Medaljon | Professor de Matemática | Campinas/SP | Abril 2021 – Setembro 2021

- Lecionei Matemática do 6º ao 9º ano, explicando conceitos complexos de forma simples.

PROJETOS

Assistente Multiagente com RAG (desafio técnico) | Código e explicação em rguto11.github.io

- Construí um orquestrador com classificador LLM (categoria e nível de confiança) que encaminha cada pergunta a um de três agentes (Financeiro, Informações Internas com RAG e Ouvidoria) e pergunta de volta quando a confiança é baixa.
- Evitei alucinação em números: o modelo preenche uma consulta validada e o código calcula; se o texto do modelo diverge dos valores calculados, o sistema o substitui.
- Entreguei com API FastAPI em Docker, interface web, abstração do provedor de LLM e log rastreável por trace_id, validados por 342 testes (262 unitários, 24 com Gemini real e 56 de navegador com Playwright).

Stack: Python, FastAPI, Gemini API, RAG, embeddings, SQLite, Pydantic, Docker, Pytest, Playwright.

NEXO: Plataforma de Analytics Conversacional Multiagente (TCC, PUC-Campinas, desenvolvimento individual)

- Desenvolvo sozinho uma plataforma em que o usuário envia CSV ou Excel e analisa os dados em português, com agentes de Dados, Análise e Visualização coordenados por um orquestrador em Python puro, sem frameworks de agentes.
- Apliquei o princípio "o LLM interpreta, ferramentas calculam": saídas estruturadas validadas por contratos, cálculos e gráficos determinísticos (Pandas, Plotly) e nenhum código arbitrário executado.
- Isolei os provedores Gemini e Ollama atrás de uma interface comum, com memória de sessão, refinamento da análise por conversa e cerca de 390 testes automatizados. Código privado; demonstração sob solicitação.

Stack: Python, Gemini API, Ollama, Structured Outputs, Pandas, Plotly, Streamlit, Pytest.

Outros projetos

- MathClass: tutor multimodal de matemática (Gemini 2.5 Flash e Streamlit) que interpreta texto e foto de exercícios, com dois modos de professor e histórico da conversa. github.com/rguto11/MathClass
- Classificação de score de crédito (projeto final da Digital House, 2022, grupo de 4): seis modelos comparados, com Random Forest a 77,6% de acurácia contra 54,1% do modelo de referência. Desenvolvi o aplicativo Streamlit. github.com/rguto11/ProjetoFinal
- Logística urbana (atividade acadêmica): três microsserviços HTTP com PostgreSQL e Docker Compose, com testes por serviço. github.com/rguto11/projeto-logistica

FORMAÇÃO ACADÊMICA

Bacharelado em Ciência de Dados e Inteligência Artificial | PUC-Campinas | Conclusão prevista: Julho 2027

Licenciatura em Matemática | PUC-Campinas | Concluído em 2020

IDIOMAS

Português: nativo | Inglês: intermediário (leitura técnica e documentação)