AUGUSTO MELO RIBEIRO

AI Engineer | LLMs e Machine Learning

Campinas/SP | (35) 98701-2408 | rguto11@gmail.com

linkedin.com/in/rguto11 | github.com/rguto11

RESUMO PROFISSIONAL

Estudante de Ciência de Dados e Inteligência Artificial (PUC-Campinas, formatura em Julho 2027) e estagiário de IA em fintech, com foco em engenharia de LLMs e Machine Learning em produção. Construo e integro soluções de software para produtos de IA: sistemas multiagente com RAG, chat analítico com LLM (GPT-4o, Gemini e Ollama) com tool calling e Text-to-SQL, modelo de churn com LightGBM e pipelines de ML automatizados com deploy em Docker e CI/CD. Base sólida em Matemática, Python e engenharia de software, com testes automatizados. Desenvolvo com IA no dia a dia (AI-assisted development). Disponibilidade de 30 horas semanais.

EXPERIÊNCIA PROFISSIONAL

ValePay | Estagiário de Inteligência Artificial | Campinas/SP | Maio 2026 – Atual

- Desenvolvi plataforma de analytics para fintech com 14 domínios de negócio isolados (Domain-Driven Design), integrando LLMs, Machine Learning e automação, com desenvolvimento assistido por IA.
- Construí chat analítico com LLM (GPT-4o e Ollama): orquestrador com memória de contexto, tool calling por domínio, schema introspection automático e validação de SQL com sqlglot (Text-to-SQL seguro), com camada de abstração que alterna entre modelo em nuvem e local e PII masking.
- Treinei modelo LightGBM multi-class de predição de churn comportamental com 60 features derivadas de dados transacionais (ratios temporais de 30/60/90 dias, tendências, frequência, ticket médio e velocidade de inatividade).
- Operacionalizei pipeline de ML agendado (APScheduler, a cada 6h): extração MySQL, feature engineering, inferência, clustering K-Means e persistência atômica em PostgreSQL, com distributed locking via Redis e scripts Lua.
- Modelei Lifetime Value normalizado por volume transacional e analisei 30 meses de dados financeiros, simulando cenários de repricing para recuperação de margem.
- Automatizei comunicação com clientes: motor de Customer Lifecycle Management com 11 réguas via WhatsApp e prioridade mutex entre funnels.
- Expus os modelos e análises em APIs REST com FastAPI (JWT com refresh token, RBAC, 2FA, rate limiting e audit logging) e dashboard Streamlit/Plotly com 28 views.
- Configurei stack Docker (API, Dashboard, Worker, PostgreSQL, Redis), CI/CD com GitHub Actions, testes com Pytest e Makefile com mais de 20 comandos automatizados.

Tecnologias: Python, LLMs, OpenAI API, Ollama, Tool Calling, Prompt Engineering, Text-to-SQL, LightGBM, Scikit-learn, K-Means, Pandas, NumPy, FastAPI, Streamlit, Plotly, PostgreSQL, MySQL, Redis, Docker, GitHub Actions, Pytest, APScheduler, Pydantic, SQLAlchemy.

Ceva Saúde Animal | Analista de BI Jr. | Paulínia/SP | Março 2026 – Maio 2026

- Desenvolvi pipelines em Python para dados comerciais e de mercado da unidade de Aves, com dashboards de vendas, market share e preços e análises usadas em negociações com clientes.

Ceva Saúde Animal | Estagiário de Business Intelligence | Paulínia/SP | Março 2024 – Fevereiro 2026

- Desenvolvi pipelines ETL em Python para dados comerciais e de mercado, automatizando processos que antes eram manuais.
- Construí dashboards em Power BI e Excel com automação via Power Query e VBA para acompanhamento mensal de vendas e KPIs.
- Elaborei estudos analíticos para diretoria e time comercial, como cobertura do mercado de vacinas e estimativas de preços da concorrência.

E. E. Professor Alberto Medaljon | Professor de Matemática | Campinas/SP | Abril 2021 – Setembro 2021

- Lecionei Matemática do 6º ao 9º ano, explicando conceitos complexos de forma simples.

PROJETOS

Assistente Multiagente com RAG (desafio técnico) | github.com/rguto11/areco-multi-agent-assistant

- Orquestrador com classificador LLM (categoria e nível de confiança) que roteia perguntas para três agentes especializados (Financeiro, Informações Internas com RAG e Ouvidoria) e pede esclarecimento quando a confiança é baixa.
- RAG com embeddings e respostas com fontes. Nos dados estruturados, o modelo preenche uma consulta validada e o código calcula; se o texto do modelo diverge dos números, o sistema o substitui.
- API FastAPI em Docker, interface web, abstração de provedor de LLM com cliente falso para testes e log rastreável por trace_id. Mais de 340 testes: 262 unitários, 24 com Gemini real e 56 de navegador (Playwright).

Stack: Python, FastAPI, Gemini API, RAG, embeddings, SQLite, Pydantic, Docker, Pytest, Playwright.

NEXO - Plataforma de Analytics Conversacional Multiagente (TCC, PUC-Campinas, equipe de 3)

- Desenvolvedor principal de plataforma em que o usuário envia CSV/Excel e analisa os dados em português, com agentes de Dados, Análise e Visualização coordenados por um orquestrador em Python puro, sem frameworks de agentes.
- Princípio "o LLM interpreta, ferramentas calculam": saídas estruturadas validadas por contratos, cálculos e gráficos por ferramentas determinísticas (Pandas, Plotly) e nenhum código arbitrário executado.
- Provedores Gemini e Ollama atrás de interface comum, memória de sessão, refinamento da análise por conversa e explicação dos resultados, com cerca de 390 testes automatizados.

Stack: Python, Gemini API, Ollama, Structured Outputs, Pandas, Plotly, Streamlit, Pytest.

MathClass - Tutor Multimodal de Matemática | github.com/rguto11/MathClass

- Aplicação com Gemini 2.5 Flash que interpreta texto e foto de exercícios, com dois modos de professor, histórico de conversa e restrição de escopo via system prompt.

Stack: Python, Gemini API, Streamlit, Prompt Engineering.

FORMAÇÃO ACADÊMICA

Bacharelado em Ciência de Dados e Inteligência Artificial | PUC-Campinas | Conclusão prevista: Julho 2027

Licenciatura em Matemática | PUC-Campinas | Concluído em 2020

HABILIDADES TÉCNICAS

LLMs e IA Generativa: OpenAI API (GPT-4o), Gemini API, Ollama, LangChain, Prompt Engineering, Tool Calling, Structured Outputs, RAG, embeddings, Text-to-SQL, sistemas multiagente e orquestração de LLMs, avaliação de modelos, AI-assisted development.

Machine Learning: Scikit-learn, LightGBM, XGBoost, CatBoost, K-Means, PCA, Optuna, feature engineering, classificação, clusterização, predição de churn, validação de modelos.

Engenharia e MLOps: Python, FastAPI, APIs REST, Pydantic, SQLAlchemy, Pytest, Git, Docker, CI/CD (GitHub Actions), pipelines de ML agendados, Domain-Driven Design, React e TypeScript (noções práticas).

Dados, Bancos e BI: SQL, PostgreSQL, MySQL, Redis, Pandas, NumPy, SciPy, ETL, AWS RDS, Streamlit, Plotly, Power BI, Excel avançado, Power Query, VBA.

IDIOMAS

Português: nativo | Inglês: intermediário (leitura técnica e documentação)